

27th International Conference on Intelligent Data Engineering and Automated Learning (IDEAL 2026)

Informe de revisión por pares

Comentarios línea por línea y hoja de ruta para aceptación

Campo	Detalle
Manuscrito	A Dual Approach for Optimized Hand Gesture Recognition Using MediaPipe and AI Edge Deployment with ESP32-CAM
Autoras	S. Arteaga; V. Sánchez. School of Biological Sciences and Engineering, Universidad Yachay Tech, Ecuador
Congreso de destino	IDEAL 2026 — Manchester, UK (19–21 nov. 2026). Proceedings Springer LNCS/LNAI
Tipo de contribución	Full paper (9–12 páginas, formato LNCS, revisión rigurosa por pares)
Temas IDEAL aplicables	Machine Learning & Deep Learning; Bio-Inspired Models; Real-world Applications of Intelligent Techniques and AI
Modalidad de revisión	Doble ciego, evaluación por originalidad, significancia, calidad y claridad
Estado	Pre- envío (revisión interna previa a sumisión oficial)
Recomendación de este revisor	Reject en su estado actual / Major Revision imprescindible antes del envío. Corregir el Bloque 1 íntegro.
Convención de severidad	Mayor (M) · Moderado (m) · Menor (n)
Total de comentarios	38 comentarios línea por línea + 10 preguntas específicas
Objetivo del informe	Hoja de ruta accionable para maximizar la probabilidad de aceptación en IDEAL 2026

Carta a las autoras

Estimadas autoras:

He revisado integralmente el manuscrito sobre el sistema dual de reconocimiento de gestos de mano mediante MediaPipe y despliegue AI-at-the-Edge sobre ESP32-CAM, en el contexto de su envío previsto al 27.º IDEAL (Springer LNCS/LNAI). El propósito de este informe es ofrecer una hoja de ruta accionable y detallada para que la versión enviada supere el filtro de los revisores de IDEAL, que evalúan por originalidad, significancia, calidad técnica y claridad.

El trabajo aborda un problema legítimo de interacción humano-máquina y tiene méritos prácticos reales: integra un pipeline reproducible (MediaPipe Hands + lógica geométrica con histéresis) con un despliegue embebido genuino (FOMO/Edge Impulse sobre ESP32-CAM), reporta métricas de detección y de despliegue, y entrega un prototipo físico funcional con cinco servos. La honestidad al reportar las limitaciones (inferencia de 981 ms, confusión con fondo, sensibilidad a iluminación) es encomiable y poco frecuente en trabajos de ingeniería aplicada.

Sin embargo, identifico varias preocupaciones que considero bloqueantes para una aceptación en IDEAL y que deben tratarse antes del envío:

- Encaje (scope/fit) y posicionamiento como aporte de IDEAL. IDEAL es un congreso de ingeniería de datos inteligente y aprendizaje automatizado; valora un aporte metodológico o un análisis empírico riguroso, no una demostración de integración de componentes. En su forma actual el manuscrito se lee como un proyecto de ingeniería (system integration) sin contribución de aprendizaje novedosa, lo que es causa frecuente de rechazo por falta de novedad.
- Novedad insuficiente. MediaPipe Hands, FOMO sobre ESP32-CAM y el control de servos por I2C son tecnologías existentes y bien documentadas. No se identifica un delta metodológico claro (ni nueva arquitectura, ni nueva función de pérdida, ni nuevo protocolo de evaluación, ni dataset de valor reutilizable). La 'contribución central' declarada (mapear coordenadas de píxel a posición de dedo) es ingeniería estándar.
- Ausencia total de comparación cuantitativa (baselines y estado del arte). El related work es descriptivo y la única 'comparación' entre las dos rutas es cualitativa. No hay tabla comparativa contra métodos previos ni contra baselines alternativos sobre el mismo dataset.
- Inconsistencias internas que comprometen la credibilidad. El número de clases oscila entre dos (Open/Close) y tres (se introduce 'Index' en la Sec. 3.7 y Tabla 7 sin definirla ni evaluarla). Las cifras de la matriz de confusión difieren entre la Sec. 4.2 (CLOSE 78.6%) y la Sec. 4.4 (CLOSE 79.4%). Las confianzas de las Figs. 16–17 contradicen el texto (0.91/0.98 vs '1.00/0.90').
- Validación estadística inexistente. n=316 imágenes de un número no declarado de sujetos; un único split 80/20 sin validación cruzada, sin intervalos de confianza, sin repeticiones con distintas semillas, sin test estadístico. No se puede afirmar generalización con dos frames de 'otro sujeto'.
- Dataset minúsculo y mal caracterizado. No se declara el número de participantes, su diversidad (tono de piel, mano dominante), ni el protocolo de captura reproducible; sin esto, el riesgo de fuga de datos (data leakage) sujeto-a-split es alto.

Mi diagnóstico es que el manuscrito es honesto y el prototipo funciona, pero el aporte tal como está formulado no alcanza el umbral de novedad y rigor de IDEAL. Lo realmente defendible no es 'integrarnos MediaPipe con un ESP32-CAM', sino, potencialmente: (1) una comparación empírica controlada y reproducible entre reconocimiento landmark-based on-host y detección FOMO on-device bajo condiciones idénticas, con métricas de latencia, energía, exactitud y robustez; (2) un análisis de los trade-offs precisión-latencia-memoria-energía que oriente decisiones de diseño en edge AI; y (3) un dataset embebido caracterizado y liberado. Ese mensaje, sin embargo, no está construido: la comparación formal entre rutas se relega explícitamente a 'future work'.

Este informe presenta 38 comentarios línea por línea organizados por sección, 10 preguntas dirigidas que la carta de respuesta debe abordar, y una hoja de ruta priorizada en tres bloques. Si las autoras ejecutan íntegramente el Bloque 1 (Mayores) y al menos el 75 % del Bloque 2 (Moderados), considero que el manuscrito puede pasar de un rechazo probable a una contribución competitiva.

Cordialmente,

Revisor del Comité de Programa — IDEAL 2026

Resumen ejecutivo

Recomendación cuantitativa

Severidad	Cantidad	Significado y acción esperada
Mayor (M)	14	Bloqueante. Resolver antes del envío. Sin estos cambios, alta probabilidad de rechazo por novedad/rigor.
Moderado (m)	14	Resolver o justificar explícitamente en la carta de respuesta. Necesario para una recomendación de aceptación.
Menor (n)	10	Estilo, formato, consistencia, edición. Resolver en la mayoría; justificar excepciones.

Mensajes principales para las autoras

1. Reposicionar la contribución hacia el análisis, no la integración. IDEAL no premia 'conectar A con B'. Convertir el paper en un estudio comparativo controlado host-vs-edge con un eje de análisis claro (trade-off exactitud/latencia/energía/memoria) o en una propuesta metodológica concreta. (C-04, C-07, C-31)
2. Construir la comparación cuantitativa que hoy falta. Tabla comparativa contra estado del arte y baselines, y comparación formal entre las dos rutas bajo condiciones idénticas, con la misma métrica y los mismos datos. (C-09, C-11, C-31)
3. Introducir rigor estadístico. Validación cruzada por sujeto (no por imagen), repeticiones multi-semilla, intervalos de confianza y un test apropiado. Declarar el número de participantes. (C-13, C-14, C-25)
4. Eliminar las inconsistencias internas. Unificar dos vs tres clases (la clase 'Index' fantasma), reconciliar las matrices de confusión y las confianzas de las figuras con el texto. Estas contradicciones, por sí solas, motivan rechazo. (C-19, C-26, C-27)
5. Caracterizar y, preferentemente, liberar el dataset. Número de sujetos, diversidad, protocolo, y split sin fuga sujeto-a-partición; valor de reutilización. (C-13, C-12)
6. Medir energía y memoria de forma rigurosa, no solo tiempo. En edge AI, el consumo energético y el footprint son ejes de primer orden; hoy solo se reporta RAM/flash de Edge Impulse y un único valor de latencia. (C-22, C-30)
7. Justificar y analizar la latencia de 981 ms. Es alta para HMI en tiempo real; explicar el cuello de botella (resolución, cuantización, frecuencia de reloj) y explorar optimizaciones, no solo declararla como limitación. (C-23, C-30)

Distribución de comentarios por sección

Sección del manuscrito	Mayor	Moderado	Menor
Título, palabras clave y abstract	1	2	2
Introducción y contribuciones	2	1	1
Estado del arte / related work	2	1	0
Materiales y métodos: datos, modelo, despliegue	5	4	2
Resultados y discusión	3	4	2

Sección del manuscrito	Mayor	Moderado	Menor
Conclusión, formato y reproducibilidad	1	2	1

Comentarios línea por línea

1. Título, palabras clave y resumen

C-01 · Título · Moderado

Observación: El título ('A Dual Approach for Optimized Hand Gesture Recognition...') usa 'Optimized' sin que el manuscrito presente ninguna optimización formal: no hay búsqueda de hiperparámetros, ni estudio de cuantización comparativa, ni Pareto-front exactitud/latencia. El término sobre-promete.

Por qué es una debilidad: Un revisor de IDEAL espera que 'optimized' implique un procedimiento de optimización medible; su ausencia genera fricción desde la primera línea y sugiere imprecisión terminológica.

Acción requerida: Sustituir 'Optimized' por una formulación fiel, p. ej. 'A Comparative Study of Host-Based MediaPipe and On-Device FOMO Hand-Gesture Recognition for Low-Cost Robotic Actuation', anclando el aporte en la comparación y no en una optimización inexistente.

C-02 · Keywords · Menor

Observación: Las palabras clave ('MediaPipe; AI Edge; hand gesture recognition; ESP32-CAM; FOMO; Edge Impulse; low-cost hardware prototype') son nombres de productos/herramientas, no descriptores científicos indexables que ubiquen el trabajo en el ámbito de IDEAL.

Por qué es una debilidad: Una lista sesgada a marcas reduce la recuperabilidad y señala al revisor un enfoque de ingeniería de producto más que de aprendizaje automatizado.

Acción requerida: Incluir descriptores conceptuales: 'tiny machine learning', 'edge inference', 'human-machine interaction', 'embedded deep learning', 'latency-accuracy trade-off'. Mantener 6–8 keywords.

C-03 · Abstract — alcance · Mayor

Observación: El abstract describe lo que el sistema hace (integración) pero no formula una pregunta científica ni un hallazgo cuantitativo comparativo. Anuncia métricas ('completeness, accuracy, F1, confidence, confusion matrix') sin dar un solo número, y no declara cuál es la novedad frente al estado del arte.

Por qué es una debilidad: En IDEAL, un abstract sin pregunta de investigación, sin número clave y sin novedad explícita correlaciona fuertemente con rechazo temprano. El lector no puede distinguir este trabajo de un tutorial de integración.

Acción requerida: Reescribir en torno a: (1) pregunta ('¿cómo se comparan, bajo condiciones idénticas, el reconocimiento landmark on-host y la detección FOMO on-device en exactitud, latencia, memoria y energía?'); (2) el hallazgo cuantitativo principal; (3) la implicación de diseño. Incluir el F1=83.8 % y la latencia de 981 ms en el resumen.

C-04 · Abstract — claim de contribución · Moderado

Observación: El abstract presenta el aporte como 'mostrar que un método basado en computador puede complementarse con una versión hardware de bajo consumo'. Esto es una afirmación de viabilidad, no una contribución de conocimiento.

Por qué es una debilidad: La 'viabilidad' de integrar componentes maduros no es novedad publicable en un congreso competitivo de ML; es el punto de partida esperado.

Acción requerida: Declarar una contribución verificable: un análisis de trade-offs cuantificado, una recomendación de diseño basada en evidencia, o un artefacto reutilizable (dataset/benchmark). Ver C-31.

2. Introducción y contribuciones

C-05 · Sec. 1 — gap de investigación · Mayor

Observación: La introducción motiva el problema (latencia, dependencia de la nube, costo) pero no articula un gap de investigación abierto ni una hipótesis. Salta de 'existen dos enfoques' a 'los integramos', sin explicar qué pregunta científica no resuelta aborda el trabajo.

Por qué es una debilidad: Sin gap explícito, el revisor no puede evaluar la significancia. IDEAL exige que el trabajo se posicione frente a un problema abierto, no frente a una tarea de implementación.

Acción requerida: Añadir un párrafo que formule la pregunta abierta (p. ej. la falta de comparaciones controladas host-vs-edge bajo el mismo dataset y hardware en HMI gestual de bajo costo) y una o dos hipótesis falsables.

C-06 · Sec. 1 — lista de contribuciones ausente · Mayor

Observación: La introducción no contiene una lista explícita y enumerada de contribuciones, convención esperada en LNCS. El lector debe inferir qué es nuevo, y lo que infiere (integración + prototipo) no es novedad.

Por qué es una debilidad: La ausencia de contribuciones explícitas obliga al revisor a buscarlas, y al no encontrarlas concluye que no las hay. Es una de las causas más rápidas de rechazo.

Acción requerida: Añadir 'Our contributions are:' con 3–4 ítems verificables y defendibles tras la reestructuración (comparación controlada, análisis de trade-offs, dataset caracterizado, hallazgos de diseño edge).

C-07 · Sec. 1 — encuadre como ML, no como ingeniería · Menor

Observación: El lenguaje es de proyecto de ingeniería ('low-cost robotic hand prototype', 'servo-based physical response') más que de investigación en aprendizaje. El componente de aprendizaje (entrenamiento FOMO) ocupa un papel secundario.

Por qué es una debilidad: IDEAL es un foro de automated learning; un encuadre de ingeniería de hardware desorienta sobre el fit.

Acción requerida: Reencuadrar la introducción para que el aprendizaje (modelo, datos, evaluación, generalización edge) sea el eje, y el prototipo el banco de pruebas, no el fin.

3. Estado del arte y posicionamiento

C-08 · Sec. 2 / Tablas 1–3 — SOTA descriptivo · Mayor

Observación: Las tres tablas de estado del arte enumeran trabajos con columnas 'Focus / Approach / Relevance' pero sin una sola métrica numérica ni una comparación cuantitativa. El related work es una enumeración ('X hizo Y'), no un análisis crítico.

Por qué es una debilidad: Sin métricas reportadas de trabajos previos, el lector no puede situar un F1 de 0.84 en el estado del arte. Un revisor lo leerá como ausencia de comparación, objeción recurrente y bloqueante.

Acción requerida: Añadir, en al menos una tabla, columnas con dataset, métrica principal y valor reportado por cada trabajo cercano (precisión/F1, latencia, plataforma). Reescribir cada entrada con el patrón: 'el trabajo X reportó Z PERO carece de A; el presente trabajo aborda A'.

C-09 · Sec. 2 — ausencia de comparación con TinyML gestual · Mayor

Observación: Existe literatura específica de reconocimiento de gestos en microcontroladores y de benchmarking TinyML (incluida una de las propias referencias, Heydari & Mahmoud 2025) que no se usa para comparar cuantitativamente. No se compara FOMO contra alternativas embebidas (p. ej. MobileNet cuantizado, modelos TFLite-Micro propios).

Por qué es una debilidad: Sin baseline embebido alternativo, no se puede afirmar que FOMO sea una buena elección; la decisión de arquitectura queda injustificada empíricamente.

Acción requerida: Incluir al menos un baseline embebido alternativo bajo el mismo dataset y hardware (p. ej. un clasificador TFLite-Micro o un detector cuantizado distinto), y comparar exactitud, latencia, RAM, flash y energía.

C-10 · Sec. 2 — posicionamiento de novedad · Moderado

Observación: El manuscrito no declara en qué se diferencia de los híbridos MediaPipe+clasificador ya citados (Padhi & Das; Liao et al.). La combinación 'MediaPipe on-host + FOMO on-device' no se contrasta con esos antecedentes.

Por qué es una debilidad: La novedad incremental debe demostrarse explícitamente frente a lo más cercano; de lo contrario se asume inexistente.

Acción requerida: Añadir un párrafo de delta-de-novedad que explicita qué aporta el enfoque dual frente a cada antecedente híbrido.

4. Materiales y métodos

C-11 · Sec. 3.1 — comparación entre rutas relegada · Mayor

Observación: Las dos rutas (MediaPipe on-host, FOMO on-device) se describen por separado y nunca se comparan bajo condiciones idénticas. La comparación formal se difiere explícitamente a future work (Sec. 4.4: 'a more formal comparison... should be included').

Por qué es una debilidad: La comparación es, potencialmente, el único aporte de valor del trabajo; relegarla a future work vacía el manuscrito de contribución. Las dos rutas además ni siquiera detectan las mismas clases ni usan el mismo protocolo.

Acción requerida: Ejecutar la comparación dentro de este paper: mismos gestos, mismos sujetos/condiciones, mismas métricas (exactitud, latencia extremo-a-extremo, memoria, energía, estabilidad). Es el cambio estructural de mayor retorno.

C-12 · Sec. 3.2.4 — dataset: tamaño y procedencia · Mayor

Observación: El dataset FOMO es de 316 imágenes (161 open / 155 close), split 80/20 (253/63). No se declara el número de participantes, su diversidad demográfica, ni cómo se evitó la fuga sujeto-a-split. Las imágenes de un mismo sujeto/sesión podrían estar en train y test.

Por qué es una debilidad: Con un split por imagen y sin separación por sujeto, las métricas pueden estar infladas por memorización de fondo/manos del mismo sujeto. 316 imágenes es, además, insuficiente para afirmar generalización.

Acción requerida: Declarar número de sujetos y protocolo; rehacer el split por sujeto (subject-wise) o por sesión; ampliar el dataset; y validar con sujetos no vistos. Reportar la composición exacta de train/val/test por sujeto.

C-13 · Sec. 3.2.4 / 3.5 — sin validación cruzada ni repeticiones · Mayor

Observación: Se entrena una sola vez con un único split 80/20, 100 épocas, $lr=0.001$, batch=128. No hay k-fold, ni repeticiones con distintas semillas, ni intervalos de confianza. El F1=83.8 % es un punto único sin incertidumbre.

Por qué es una debilidad: Una métrica puntual sin varianza no es evaluable: no se sabe si 83.8 % es estable o producto del azar del split. IDEAL valora el rigor empírico.

Acción requerida: Reportar k-fold (o al menos múltiples semillas) con media $\pm$ desviación e intervalos de confianza para todas las métricas clave. Comparar rutas y baselines bajo este protocolo.

C-14 · Sec. 3.3 / Fig. 5 — FOMO con 3 clases declaradas pero 2 entrenadas · Mayor

Observación: El pipeline (Fig. 5) y la Sec. 3.3 describen dos clases (open/close), pero la Sec. 3.7 y la Tabla 7 evalúan 'Close, Open, or Index'. La clase 'Index' nunca se define, ni se incluye en el dataset, ni aparece en la matriz de confusión.

Por qué es una debilidad: Una clase fantasma en el protocolo de evaluación sugiere descuido o reutilización no depurada de plantillas; mina la confianza en todo el aparato experimental.

Acción requerida: Decidir el número de clases y aplicarlo consistentemente en dataset, entrenamiento, métricas y figuras. Si 'Index' no se entrena, eliminar toda mención.

C-15 · Sec. 3.2.2/3.2.3 — umbrales geométricos sin justificación · Moderado

Observación: Los umbrales de histéresis (−0.015/0.035 para dedos; −0.005/0.02 para pulgar) y el umbral de confianza 0.60 se presentan como valores fijos sin derivación, sin análisis de sensibilidad y sin validación.

Por qué es una debilidad: Umbrales 'mágicos' sin justificación parecen ajustados a mano sobre los datos de prueba, lo que es una forma de sobreajuste no controlado.

Acción requerida: Justificar los umbrales (sobre un conjunto de calibración separado) y reportar la sensibilidad del desempeño a su variación (curvas de barrido).

C-16 · Sec. 3.4 — augmentación y posible fuga · Moderado

Observación: Se aplica data augmentation (brillo, rotaciones, desplazamientos, zoom). No se aclara si la augmentación se aplica solo a train (correcto) o también afecta a las particiones de validación, ni cómo interactúa con el split por imagen.

Por qué es una debilidad: Aumentar antes de separar, o separar por imagen y no por sujeto, infla las métricas.

Acción requerida: Confirmar explícitamente que la augmentación se aplica solo tras el split y solo a train; documentar el orden de operaciones.

C-17 · Sec. 3.5 — un único valor de latencia · Moderado

Observación: La latencia de inferencia (981 ms) se reporta como valor único, sin distribución (media, desviación, percentiles) ni desglose por etapa (captura, resize, inferencia, I2C, actuación).

Por qué es una debilidad: Sin distribución ni desglose, no se puede razonar sobre el cuello de botella ni sobre la variabilidad de la respuesta.

Acción requerida: Reportar latencia con estadísticos sobre múltiples inferencias y desglose por etapa del pipeline; separar inferencia pura de comunicación y actuación.

C-18 · Sec. 3.4/3.6 — código y configuración no liberados · Menor

Observación: Se describen el impulso (96×96 RGB, FOMO MobileNetV2 0.35) y los hiperparámetros, pero no hay enlace a repositorio, modelo exportado, dataset ni script reproducible.

Por qué es una debilidad: La reproducibilidad es un criterio creciente; su ausencia resta puntos y dificulta la verificación.

Acción requerida: Liberar código, modelo .eim/.tflite, dataset y un README reproducible (p. ej. Zenodo/GitHub con DOI).

C-19 · Sec. 3.7 — métricas heredan la inconsistencia de clases · Menor

Observación: La Tabla 7 define precisión/recall/F1/matriz de confusión sobre 'Close, Open, or Index', arrastrando la clase fantasma de C-14 a toda la definición de métricas.

Por qué es una debilidad: Definir métricas sobre una clase inexistente confunde y resta credibilidad.

Acción requerida: Reescribir la Tabla 7 con las clases realmente evaluadas.

5. Resultados y discusión

C-20 · Sec. 4 — comparación host-vs-edge solo cualitativa · Mayor

Observación: El único contraste entre rutas es verbal ('la respuesta fue más lenta en la ruta FOMO'). No hay una tabla que enfrente, con números, exactitud, latencia, memoria y energía de ambas rutas sobre los mismos gestos.

Por qué es una debilidad: El lector no puede cuantificar el trade-off central que el propio título insinúa ('dual approach'). El aporte queda como impresión, no como evidencia.

Acción requerida: Añadir una tabla comparativa cabeza-a-cabeza host-vs-edge con todas las métricas y, si procede, un diagrama de trade-off (exactitud vs latencia vs energía).

C-21 · Sec. 4.2/4.4 — matriz de confusión inconsistente · Mayor

Observación: La Sec. 4.2 reporta CLOSE 78.6 % (21.4 % confundido con fondo) y OPEN 81.5 %. La Sec. 4.4 reporta CLOSE 79.4 % (20.6 % fondo) y OPEN 81.5 %. Los dos valores de CLOSE son incompatibles para la misma matriz.

Por qué es una debilidad: Cifras contradictorias para el mismo experimento son un fallo de control de calidad que un revisor marcará de inmediato y que erosiona la confianza en todos los demás números.

Acción requerida: Reconciliar y reportar una única matriz de confusión verificable; auditar todas las cifras del manuscrito contra la fuente (Edge Impulse) para coherencia.

C-22 · Sec. 4 — ausencia de medición de energía · Mayor

Observación: Para un trabajo de AI Edge de bajo consumo, no se mide el consumo energético (mA/mW por inferencia, autonomía con la batería declarada). Solo se reportan RAM/flash de Edge Impulse.

Por qué es una debilidad: La energía es un eje central del edge AI; omitirla deja sin sustento el argumento 'low-power' del título y del abstract.

Acción requerida: Medir corriente/potencia por inferencia y en reposo; estimar autonomía. Incluir energía en la comparación host-vs-edge.

C-23 · Sec. 4.4/4.5 — latencia de 981 ms sin análisis causal · Moderado

Observación: Los 981 ms se declaran y se lamentan como limitación, pero no se analiza la causa (resolución 96×96, MobileNetV2 0.35, reloj del ESP32, int8) ni se exploran mitigaciones (menor resolución de entrada, poda, frecuencia de CPU, modelo alternativo).

Por qué es una debilidad: Sin análisis causal ni intento de optimización, la contribución de ingeniería tampoco se materializa; queda como una observación pasiva.

Acción requerida: Diagnosticar el cuello de botella y reportar al menos un experimento de optimización con su efecto en latencia y exactitud.

C-24 · Sec. 4.2 — F1=83.8 % sin contexto comparativo · Moderado

Observación: El F1=83.8 % se presenta de forma aislada, sin comparación con baselines ni con la literatura, y sin intervalo de confianza (ligado a C-13 y C-08).

Por qué es una debilidad: Un número sin referencia no permite juzgar si es bueno o mediocre para la tarea.

Acción requerida: Contextualizar frente a baselines y SOTA, con incertidumbre; discutir si 83.8 % es suficiente para la aplicación pretendida.

C-25 · Sec. 4.2 — 'generaliza' con n=2 frames · Moderado

Observación: Se afirma que el modelo 'generaliza más allá de las condiciones de entrenamiento' a partir de dos frames de un único sujeto adicional (Figs. 16–17).

Por qué es una debilidad: Dos imágenes no sustentan ninguna afirmación de generalización; es una sobreinterpretación estadísticamente vacía.

Acción requerida: Evaluar sobre un conjunto de sujetos no vistos con tamaño adecuado y reportar métricas agregadas; retirar la afirmación hasta tenerlas.

C-26 · Figs. 14–17 — confianzas contradicen el texto · Moderado

Observación: El texto (Sec. 4.2) afirma confianzas de 1.00 (open) y 0.95 (close), y para el segundo sujeto '1.00 y 0.90'; pero las Figs. 16–17 muestran 0.91 (open) y 0.98 (close). Los pares no coinciden.

Por qué es una debilidad: La discordancia texto-figura es un fallo de consistencia que, sumado a C-21, sugiere falta de verificación cruzada.

Acción requerida: Corregir para que texto, pies de figura y valores en imagen coincidan exactamente.

C-27 · Sec. 4.2 — '466 imágenes negativas' no trazables · Menor

Observación: La discusión de falsos positivos del informe de referencia menciona 63/466 negativos, pero en este manuscrito el dataset declarado es de 316 imágenes; aparecen conteos (p. ej. el subconjunto de prueba de 63) cuyo origen no se traza claramente en el cuerpo.

Por qué es una debilidad: Conteos no trazables al dataset declarado confunden y abren dudas sobre la procedencia de los datos de evaluación.

Acción requerida: Trazar explícitamente cada conteo (train/val/test, positivos/negativos) al dataset declarado en una única tabla de composición de datos.

C-28 · Sec. 4.4 — atribución de fallos sin evidencia controlada · Menor

Observación: Se atribuyen los errores a iluminación, fondo, distancia y resolución, pero sin un experimento controlado que aisle cada factor (ablation de condiciones).

Por qué es una debilidad: Las explicaciones plausibles sin evidencia controlada son especulación; IDEAL valora la atribución empírica.

Acción requerida: Diseñar un pequeño estudio factorial (iluminación × distancia × fondo) para cuantificar el efecto de cada factor en el F1.

6. Conclusión, reproducibilidad y formato**C-29 · Sec. 5 — conclusión sin hallazgo cuantitativo · Mayor**

Observación: La conclusión reitera que ambos enfoques 'pueden trabajar juntos' y que el prototipo 'fue funcional', sin destilar un hallazgo cuantitativo, una recomendación de diseño ni una lección generalizable.

Por qué es una debilidad: Una conclusión sin hallazgo confirma la percepción de que el trabajo es una demostración de integración, no investigación.

Acción requerida: Cerrar con el hallazgo cuantitativo principal (el trade-off medido) y una recomendación accionable de diseño para HMI gestual en edge de bajo costo.

C-30 · Sec. 4.5 — future work hace el trabajo del paper · Moderado

Observación: La sección de trabajo futuro lista justamente lo que haría publicable el paper: comparación formal entre rutas, más clases, más sujetos, optimización de latencia. Es decir, el aporte real está diferido.

Por qué es una debilidad: Cuando el future work contiene la contribución, el manuscrito presente carece de ella.

Acción requerida: Migrar al cuerpo del paper, como resultados, la comparación formal y al menos una optimización de latencia; dejar en future work solo extensiones genuinas.

C-31 · Global — reposicionamiento del aporte · Moderado

Observación: El manuscrito necesita un eje de contribución único y defendible. Hoy es 'integramos y funciona'; debería ser 'analizamos y aprendimos X que orienta el diseño'.

Por qué es una debilidad: Sin eje de contribución, ningún arreglo cosmético salvará la evaluación de novedad/significancia.

Acción requerida: Elegir y ejecutar uno de: (A) estudio comparativo host-vs-edge con trade-offs; (B) propuesta metodológica (p. ej. fusión de las dos rutas con conmutación adaptativa según confianza/energía); (C) benchmark + dataset embebido liberado y caracterizado.

C-32 · Formato — cumplimiento LNCS y longitud · Menor

Observación: El manuscrito está en plantilla MDPI ('Journal Not Specified'), no en Springer LNCS/LNAI, y con 19 páginas y ~30 figuras/tablas excede con holgura el límite de IDEAL (9–12 páginas incluidas referencias).

Por qué es una debilidad: El incumplimiento de formato y longitud puede provocar rechazo administrativo (desk-reject) antes de la revisión técnica.

Acción requerida: Migrar a la plantilla LNCS oficial y recortar a ≤12 páginas (idealmente 9), consolidando figuras y tablas y moviendo material secundario a un apéndice/repositorio.

C-33 · Inglés científico y consistencia terminológica · Menor

Observación: Hay deslices terminológicos ('completeness' por recall; 'backgroundless classes' por non-background) y mezcla de 'accuracy/precision'. Algunas frases son largas y la nomenclatura de clases es inconsistente (Close/close, Open/open).

Por qué es una debilidad: La imprecisión terminológica en métricas de ML es especialmente penalizada en un foro de aprendizaje.

Acción requerida: Edición de inglés científico; usar la terminología estándar (precision, recall, F1) de forma consistente; unificar nombres de clases y siglas en su primera aparición.

Preguntas específicas para las autoras

Las siguientes 10 preguntas deben responderse explícitamente en la carta de respuesta. Algunas exigen experimentos adicionales; otras solo aclaraciones.

8. ¿Cuál es la contribución científica que distingue este trabajo de los híbridos MediaPipe+clasificador ya publicados (Padhi & Das; Liao et al.) y de los despliegues FOMO/Edge Impulse existentes? (C-04, C-06, C-10, C-31)
9. ¿Cuántos participantes componen el dataset de 316 imágenes y cómo se garantizó que no haya fuga sujeto-a-split entre train y test? (C-12)
10. ¿Pueden reportar todas las métricas con validación cruzada (o múltiples semillas) e intervalos de confianza, en lugar de un único split 80/20? (C-13)
11. ¿Qué es la clase 'Index' que aparece en la Sec. 3.7 y la Tabla 7? ¿Está en el dataset y en la matriz de confusión, o es un residuo a eliminar? (C-14, C-19)
12. ¿Por qué los porcentajes de CLOSE difieren entre la Sec. 4.2 (78.6 %) y la Sec. 4.4 (79.4 %)? ¿Cuál es la matriz de confusión correcta? (C-21)
13. ¿Por qué las confianzas del texto (1.00/0.95; 1.00/0.90) no coinciden con las de las Figs. 16–17 (0.91/0.98)? (C-26)
14. ¿Pueden ejecutar dentro del paper la comparación formal host-vs-edge bajo condiciones idénticas (mismos gestos, sujetos, métricas), hoy relegada a future work? (C-11, C-20, C-30)
15. ¿Cuál es el consumo energético por inferencia y la autonomía con la batería declarada? ¿Cómo se compara con la ruta host? (C-22)
16. ¿Cuál es la causa de los 981 ms de inferencia y qué efecto tendrían optimizaciones (resolución, poda, reloj, modelo alternativo) sobre latencia y exactitud? (C-23, C-30)
17. ¿Liberarán código, modelo exportado y dataset caracterizado para reproducibilidad? ¿Bajo qué licencia? (C-18)

Hoja de ruta priorizada para aceptación

La siguiente lista organiza los cambios en tres bloques de prioridad. Si las autoras completan el Bloque 1 íntegro y $\geq 75\%$ del Bloque 2, la probabilidad de aceptación tras revisión en IDEAL es razonable. Esfuerzo estimado: 6–10 semanas.

Bloque 1 — Imprescindibles (sin estos no hay aceptación)

1. Reposicionar el aporte de 'integración' a 'análisis/propuesta': elegir y ejecutar un eje de contribución (comparación host-vs-edge con trade-offs, fusión adaptativa, o benchmark+dataset). (C-04, C-06, C-31)
2. Ejecutar la comparación cuantitativa host-vs-edge bajo condiciones idénticas, con tabla cabeza-a-cabeza (exactitud, latencia, memoria, energía, estabilidad). (C-11, C-20, C-30)
3. Introducir rigor estadístico: validación cruzada/semillas múltiples, intervalos de confianza y test apropiado; declarar el número de sujetos. (C-13, C-12)
4. Eliminar inconsistencias internas: clase 'Index' fantasma, matrices de confusión discordantes y confianzas figura-vs-texto. (C-14, C-21, C-26, C-19)
5. Rehacer el split por sujeto/sesión y ampliar/caracterizar el dataset para sustentar generalización. (C-12, C-25)
6. Añadir comparación cuantitativa con SOTA y con al menos un baseline embebido alternativo. (C-08, C-09, C-24)
7. Medir y reportar consumo energético por inferencia y autonomía. (C-22)
8. Migrar a plantilla LNCS y recortar a ≤ 12 páginas. (C-32)

Bloque 2 — Altamente recomendados (mejoran calidad y responsabilidad)

1. Formular gap de investigación, hipótesis y lista explícita de contribuciones en la introducción. (C-05, C-06)
2. Reescribir el abstract con pregunta, número clave y novedad explícita. (C-03)
3. Justificar umbrales (histéresis, confianza 0.60) sobre conjunto de calibración y reportar sensibilidad. (C-15)
4. Diagnosticar y optimizar la latencia de 981 ms con al menos un experimento. (C-23)
5. Reportar latencia con distribución y desglose por etapa. (C-17)
6. Estudio factorial de condiciones (iluminación $\times$ distancia $\times$ fondo) para atribuir fallos empíricamente. (C-28)
7. Confirmar el orden augmentación-tras-split y documentarlo. (C-16)
8. Reescribir el estado del arte con análisis crítico trabajo-por-trabajo y métricas numéricas. (C-08, C-10)

Bloque 3 — Estilo, edición y formato (cumplir mayoría)

1. Reformular el título eliminando 'Optimized' si no hay optimización formal. (C-01)
2. Ajustar palabras clave a descriptores conceptuales (TinyML, edge inference, HMI). (C-02)
3. Liberar código, modelo y dataset con DOI. (C-18)

4. Edición de inglés científico y consistencia terminológica de métricas y clases. (C-33)
5. Trazar todos los conteos de datos a una única tabla de composición. (C-27)
6. Reencuadrar el lenguaje hacia aprendizaje automatizado y no ingeniería de hardware. (C-07)
7. Asegurar figuras ≥ 300 dpi, legibles y autocontenidas tras la migración a LNCS. (C-32)

Estimación de tiempo y esfuerzo

Asumiendo acceso al hardware ya utilizado (ESP32-CAM, prototipo, Edge Impulse) y al pipeline implementado, los cambios del Bloque 1 son alcanzables en 6–10 semanas:

Tarea	Esfuerzo	Tiempo estimado
Reposicionamiento del aporte + reescritura del marco (intro, abstract, conclusión)	Bajo (sin re-experimentar)	1–2 semanas
Comparación host-vs-edge bajo condiciones idénticas (re-captura + medición)	Medio-Alto	2–3 semanas
Validación cruzada / multi-semilla + intervalos de confianza	Medio	4–6 días
Ampliación y re-split por sujeto del dataset	Medio (depende de captura)	1–2 semanas
Baseline embebido alternativo + tabla SOTA con métricas	Medio	4–6 días
Medición de energía por inferencia y autonomía	Bajo	2–3 días
Diagnóstico y optimización de latencia (≥ 1 experimento)	Medio	3–5 días
Corrección de inconsistencias (clases, matrices, confianzas)	Bajo	1–2 días
Migración a LNCS, recorte a ≤ 12 páginas y carta de respuesta	Bajo-Medio	1–2 semanas
TOTAL estimado	—	6–10 semanas

Síntesis final y recomendación

Principales fortalezas del manuscrito

- Prototipo físico funcional end-to-end: del gesto a la actuación de cinco servos, con dos rutas implementadas y operativas.
- Honestidad al reportar limitaciones (latencia de 981 ms, confusión con fondo, sensibilidad a iluminación), poco común en trabajos aplicados.
- Pipeline de control on-host bien descrito: lógica geométrica de estados de dedo con filtro de histéresis y umbrales asimétricos razonados.
- Tema de interés real (HMI gestual de bajo costo en edge) y motivación práctica clara (independencia de la nube, costo, latencia).
- Despliegue embebido genuino con cuantización int8 (EON) que cabe en las restricciones del ESP32-CAM.

Principales debilidades

- Novedad insuficiente: integración de componentes maduros sin delta metodológico; la contribución declarada es ingeniería estándar.
- Comparación host-vs-edge —el aporte potencial— relegada a future work; no hay tabla cuantitativa que la sustente.
- Sin comparación con estado del arte ni baselines; related work meramente descriptivo y sin métricas.
- Rigor estadístico ausente: split único por imagen, sin CV, sin intervalos de confianza, sin test; n=316 sin sujetos declarados.
- Inconsistencias internas serias: clase 'Index' fantasma, matrices de confusión discordantes, confianzas figura-vs-texto.
- Sin medición de energía pese al encuadre 'low-power'; latencia alta sin análisis causal ni optimización.
- Incumplimiento de formato y longitud (plantilla MDPI, 19 páginas) frente a LNCS ≤ 12 páginas.

Aspectos críticos que deben corregirse antes del envío

De forma no negociable, antes de enviar a IDEAL 2026: (1) reposicionar el aporte de 'integración' a 'análisis/propuesta'; (2) ejecutar la comparación cuantitativa host-vs-edge dentro del paper; (3) introducir rigor estadístico (CV, intervalos de confianza, sujetos declarados, re-split por sujeto); (4) eliminar todas las inconsistencias internas; (5) añadir comparación con SOTA y un baseline embebido; (6) medir energía; (7) migrar a LNCS y recortar a ≤ 12 páginas. Estos siete puntos concentran el riesgo de rechazo.

Probabilidades estimadas

Escenario	Probabilidad estimada	Condición
Aceptación (tras revisión)	5–10 %	Estado actual, sin cambios
Aceptación (tras revisión)	45–55 %	Si se completa íntegro el Bloque 1 y ≥ 75 % del Bloque 2

Escenario	Probabilidad estimada	Condición
Rechazo (desk-reject por formato/longitud)	Alto si no se migra a LNCS ≤ 12 pp.	Estado actual de formato
Rechazo (por novedad/rigor)	70–80 %	Estado actual, principalmente por falta de novedad y de comparación/estadística
Rechazo residual	15–20 %	Tras completar el Bloque 1 (riesgo remanente por novedad incremental)

Nota: estas probabilidades son un juicio cualitativo de revisor, no una predicción calibrada. El factor de mayor incertidumbre es la novedad; si el comité considera el trabajo una integración sin aporte de aprendizaje, el rechazo es probable pese a que el prototipo funcione. Por ello, el Bloque 1 (especialmente C-11/C-20 y C-31) es la inversión de mayor retorno.

Recomendación final

NO ENVIAR TODAVÍA. Recomiendo una revisión mayor (major revision) interna antes del envío oficial a IDEAL 2026. El prototipo es funcional y el reporte de limitaciones es honesto —calidades reales—, pero en su forma actual el manuscrito presenta un riesgo elevado de rechazo por falta de novedad, ausencia de comparación cuantitativa y rigor estadístico, e inconsistencias internas, además de incumplimiento de formato/longitud.

La narrativa correcta y defendible sería: 'Bajo condiciones idénticas de gestos, sujetos y hardware, comparamos cuantitativamente el reconocimiento de gestos landmark-based on-host (MediaPipe) frente a la detección FOMO on-device (ESP32-CAM), caracterizando el trade-off exactitud–latencia–memoria–energía y derivando recomendaciones de diseño para HMI gestual de bajo costo en el borde; liberamos el dataset embebido y el código para reproducibilidad.' Esta narrativa es alcanzable con el hardware actual tras: (a) reposicionar el aporte; (b) ejecutar la comparación y los baselines; (c) introducir rigor estadístico; (d) corregir inconsistencias; (e) medir energía; (f) cumplir el formato LNCS.

Sugiero que las autoras: (a) lean cada uno de los 38 comentarios; (b) preparen una carta de respuesta punto-por-punto citando cada ID; (c) marquen los cambios en el manuscrito; (d) si discrepan con algún comentario, lo justifiquen explícitamente. Con un esfuerzo de 6–10 semanas siguiendo el Bloque 1, el manuscrito puede convertirse en una contribución competitiva para IDEAL.

Cordialmente,

Revisor del Comité de Programa — IDEAL 2026